


Ho riaperto la mia tesi 5 anni dopo

Da R a Python, usando l'AI come sparring partner per rivedere codice, metodo e risultati.

Google Store · ML · Imbalanced data



Un esercizio nel tempo libero: non “vendere” un modello, ma capire cosa rifarei diversamente oggi.

Perché rifarla oggi?

Non per cambiare il passato. Per fare domande migliori.



L'AI non “ha fatto il lavoro al posto mio”: mi ha aiutato a rileggere criticamente codice e metodologia.

Il problema era raro

Prevedere acquisto / non acquisto nelle sessioni Google Store.

25.000

sessioni nel campione

323

sessioni con acquisto

1,3%

classe positiva

Distribuzione target



98,7% non acquisto

1,3% acquisto

**La trappola: anche un modello inutile
supera il 98% di accuracy se predice
sempre “non acquisto”.**

Accuracy $\neq$ modello utile

Riaprire il codice è stato utile

Non solo conversione: code review, metodo e riproducibilità.

01

Target dicotomizzata

Descritta nella tesi, ma assente dagli script salvati.

02

Colonne per posizione

Alcuni riferimenti tipo `[,10]` non puntano alla target nel dataframe ricostruito.

03

Balancing & ROC

SMOTE/ROSE/MWMOTE e curve ROC avevano passaggi da rendere più robusti.

La cosa positiva: le conclusioni centrali della tesi non vengono demolite. Si capisce meglio il perimetro del problema.


La conclusione 2021 regge

Su dataset sbilanciati, il balancing aumenta la sensitivity ma riduce la precision.

Prima del balancing

Dopo il balancing

Sensitivity
↑ fino a ~98%



Non è “bene” o “male”: dipende dal costo di perdere un acquisto rispetto al costo di inseguire falsi positivi.

La metrica deve seguire il problema

La domanda nuova

Stiamo classificando una sessione completa o prevedendo in anticipo?

Session-complete



source → pageviews → hits

Uso anche segnali accumulati durante la sessione.

Early-session



source → device → time

Uso solo informazioni disponibili prima della conclusione.

Questa distinzione cambia completamente il significato del modello.

La differenza si vede nei numeri

PR-AUC sul temporal holdout: più severa e utile con eventi rari.

Mixed complete




Numeric complete



Mixed early



Numeric early



Baseline



Cosa significa?

Con hits/pageviews il modello discrimina molto bene. Senza, il problema diventa molto più difficile; le feature qualitative recuperano parte dell'informazione.

Cosa mi porto a casa

Il valore non è “aver rifatto la tesi”. È averla guardata con occhi diversi.

- 01 **La domanda conta più dell'algoritmo**
- 02 **L'accuracy può raccontare una storia comoda, ma incompleta**
- 03 **Data visualization = ponte tra dati, metodo e stakeholder**
- 04 **L'AI è utile quando aiuta a dubitare meglio**

Non un progetto “perfetto”. Un esercizio personale per rivedere un vecchio lavoro, ritrovare curiosità e trasformare codice in una storia più chiara.

Next: notebook + README + post